SVEUČILIŠTE U ZAGREBU

FAKULTET ELEKTROTEHNIKE I RAČUNARSTVA

SEMINAR

Detekcija izmjena na digitalnim fotografijama

Zrinka Cvitanović

Voditelj: *doc. dr. sc. Juraj Petrović*

Zagreb, svibanj, 2025.

Sadržaj

1. Uvod 1

2. Izmjene nad slikama 2

2.1 Metode uočavanja izmjena 2

2.1.1 RGB i HSV prikaz 3

3. Detekcija umetnutih ili kloniranih objekata 4

3.1 Algoritmi za prepoznavanje rubova 4

3.2 Detekcija blokova 4

3.3 ELA (engl. Error Level Analysis) 6

3.4 Analiza šuma 7

3.5 Analiza glavnih komponenti 8

3.6 Analiza JPEG tablica 10

3.7 Analiza gradijenta osvjetljenja (engl. *Luminence gradient)* 0

4. Sažetak 2

5. Zaključak 3

6. Literatura 4

1. Uvod

Uređivači teksta postaju sve sofisticiraniji, a u zadnje vrijeme većina njih ima ugrađene značajke koje koriste umjetnu inteligenciju. Pozitivna posljedica toga je što gotovo svatko može uređivati fotografije bez velikog znanja o tome, no negativna posljedica je to što izmjene postaju sve teže zamjetne. Nije problem ako se ne primijeti da je neka slika retuširana ili općenito da je suptilno poboljšana, ali je problem kad se te značajke koriste u prikrivanju nekih većih izmjena poput umetanja, brisanja objekata ili sličnih promjena semantike slike.

Također, sve je veći problem ustanoviti je li neka fotografija autentična, ali ne samo jesu li neki detalji istiniti, već je li ono što se prikazuje uopće istinito. Generativni alati koji koriste umjetnu inteligenciju postali su dostupni javnosti i besplatni te svatko s internetskom vezom može generirati gotovo bilo kakvu sliku.

Iako forenzička analiza ne može pouzdano reći je li neka slika autentična ili nije, postoje metode koje mogu s određenom dozom sigurnosti reći je li došlo do izmjene te, ako je, do koje i na kojem mjestu. Ovaj će seminarski rad pokriti neke jednostavnije izmjene slika i opisati kako laik može s određenom sigurnošću provjeriti vjerodostojnost neke slike bez da zove forenzičara. Iako iza svakog od tih alata leži golemo forenzičko znanje, njihovo je korištenje relativno jednostavno ako osoba poznaje osnove analize slike.

2. Izmjene nad slikama

Izmjene na slikama mogu se podijeliti u nekoliko kategorija[1]:

1. **retuširanje** (engl. *retouching*)
2. **kombiniranje više slika** (engl. *splicing*)
3. ***copy-move*** i ***copy-paste***

Ovaj će se rad fokusirati na drugu i treću kategoriju. Važnije je provjeriti je li očuvana semantika neke slike nego utvrditi je li ona uljepšana, a da je pritom zadržala isti sadržaj. Doduše, retuširanje nije nevažna tema jer se upravo ta tehnika može koristiti za prikrivanje drugih tipova izmjena koje bi inače ostavile vizualne tragove na slici.

2.1 Metode uočavanja izmjena

Metode za detekciju izmjena nad digitalnim slikama grubo se dijele na aktivne i pasivne. Podjela metoda detaljnije je prikazana na slici 1. [1]

Aktivne metode zahtijevaju manje pretprocesiranja od pasivnih metoda. [9] One koriste tehnike digitalnih potpisa ili vodenih žigova. Što god se koristilo, mora se unaprijed umetnuti u sliku, zato se metode zove aktivnima. Nedostatak tih metoda je što nekad znaju smanjiti kvalitetu slike

Pasivne metode mogu detektirati mnoge jednostavne izmjene poput *copy-move* izmjene (objekt sa slike je dupliciran u istoj slici), *splicing* (dio slike je izrezan) i još neke metode. Ovaj se rad fokusira isključivo na pasivne metode.

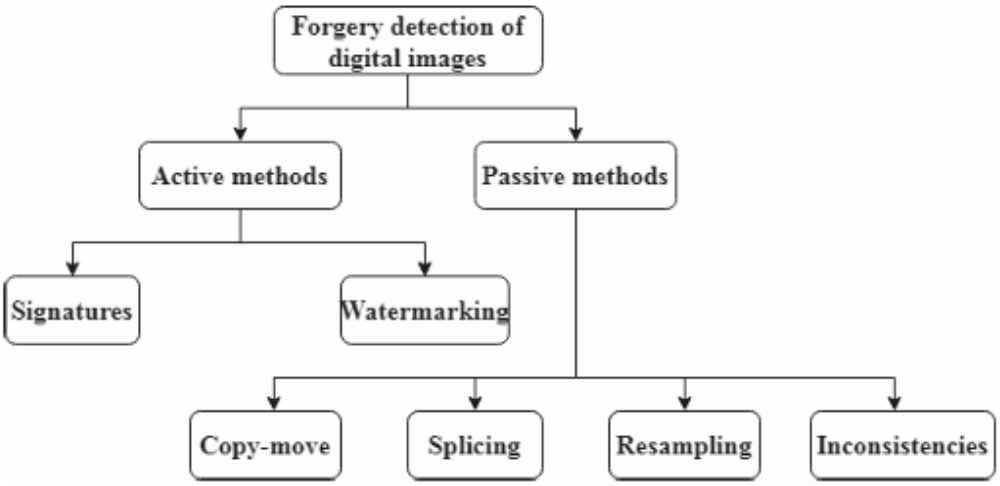

Slika 1: Podjela metoda

2.1.1 RGB i HSV prikaz

RGB je standardan prikaz slika na računalu koji prikazuje svaki piksel na temelju toga koliko sadrži crvene, zelene i plave boje. Osim toga, postoji i **Hue-Saturation-Value (HSV**) prikaz.[2] Svaki piksel se prikazuje na temelju toga kolika je jačina boje (engl. *hue*) i koliko je zasićen (engl. *saturation*). Nekonzistentnosti u HSV prikazu ukazuju na izmjenu slike. Onaj tko ju mijenja sliku obično se trudi da RGB prikaz izgleda uvjerljivo ne misleći pritom na HSV pa je to dobar način za početi provjeru slike.

3. Detekcija umetnutih ili kloniranih objekata

Umetanje i kloniranje objekata još uvijek je česta metoda izmjene slika. Nekad je to bilo teže i ovisilo je jako o spretnosti osobe jer bi se gotovo uvijek vidjeli rubovi ili grubi prijelaz osvjetljenja pa je izmjena bila očita. Problem je što danas mnogi uređivači alata imaju *auto-brightness* opciju koja će ujednačiti taj objekt sa svima ostalim i učiniti ga dijelom slike. Usprkos tome, postoje metode koje mogu prepoznati čak i tako izmijenjene slike. [3]

Razlikuju se dvije vrste umetanja objekata – ***copy-paste*** koji podrazumijeva da je objekt s **iste** fotografije kopiran i zalijepljen na još jedne mjesto i ***copy-move*** koji uzima i lijepi objekte s **različite** slike (ili više njih). *Copy-move* je često lakši za primijetiti jer je druga fotografija gotovo sigurno snimana s drugom kamerom i drugim svjetlom, no nije nužno tako.

3.1 Algoritmi za prepoznavanje rubova

Algoritmi za prepoznavanje ruba koriste se u računalnom vidu kako bi se odvojili objekti jedni od drugih i od pozadine te kako bi se moglo analizirati o kojem je objektu riječ. [2] Osim toga, imaju primjenu u detekciji umetnutih objekata jer umetnuti objekti često imaju dvostruki rub. Taj se fenomen javlja zato što uređivači teksta malo zamagle područje oko umetnutog objekta kako bi prijelaz izgledao glađe i prirodnije. Algoritam za detekciju rubova taj zamagljen dio nekad tretira kao odvojen objekt pa detektira njegov rub i rub originalnog objekta pa se vidi dvostruki rub. Analiza se provodi tako da se preko grupe piksela prelazi matricom koji nazivamo **maska**. Osim detekcija rubova i anomalija na rubovima ova metoda može otkriti i neke druge izmjene na slici zato što pruža alternativni prikaz slike koji je jako različit od onog koji je vidljiv ljudskom oku. Svatko tko izmjenjuje sliku trudi se da se izmjena ne vidi na uobičajenom prikazu, ali u drugačijim prikazima neke anomalije mogu isplivati na površinu.

3.2 Detekcija blokova

Jedan od starijih načina provjere kloniranih objekata je podjela slike na preklapajuće blokove (tzv. ***block-based*** **pristup**).[1] Među tim blokovima provjerava se postoje li dva koja su izrazito slična. Ako postoje, vrlo vjerojatno je jedan kloniran na mjesto drugog.

Osim ovog pristupa postoji i tzv. ***key-point*** **pristup**.[3] On je manje precizan od prvog, ali i jeftiniji za izračun. Slika se umjesto na blokove podijeli na ključne točke. To su točke koje se ističu i ostaju nepromjenjive pri skaliranju i rotaciji. Iz tih ključnih točaka izvlače se neka lokalna svojstva i na taj način se pronalaze duplicirane regije slike.

Na slikama niže demonstrirano je uočavanje *clone-detection* modifikacije pomoću alata Forensically. Korištena je njihova demo slika. Iako na prvu ne izgleda tako,

oblaci su klonirani. To se vrlo jasno vidi na **slici 3**. Ipak, treba imati na umu da ovakav način detekcije nikad ne može reći sa stopostotnom sigurnošću da je objekt umetnut jer detekcija izrazito ovisi o parametrima koji se postave. Ako je minimalna zahtijevana sličnost premala, moguće je da neki objekti koji su samo slični budu proglašeni klonovima. Zato treba iskoristiti još neku metodu provjere i treba isprobati mnogo različitih parametara.

Slika 2: Modificirana slika

Slika 3: Uočeni klonovi na slici

3.3 ELA (engl. Error Level Analysis)

Ova metoda analizira pojedina područja slike i gleda razliku u njihovom omjeru kompresije. [6] Identificiraju se područja koja imaju različitu razinu kompresije od ostalih. JPEG slike obično imaju u cijelosti otprilike istu razinu kompresije jer JPEG kompresija radi na cijeloj slici odjednom. Dakle, ako se nađe dio slike koji je značajno drugačiji od ostatka, to ukazuje na vjerojatnu manipulaciju na tom dijelu.

Treba napomenuti da će rubovi objekata ili neke neobične teksture gotovo sigurno izgledati drugačije pod ELA nego ostali objekti. [4] No, među svim rubovima na slici ne bi smjelo biti previše razlike, dakle svi bi trebali u otprilike jednakoj mjeri odudarati od ostatka slike. Teksture će također izgledati nešto drugačije od ostatka slike, ali bi ista tekstura trebala izgledati ujednačeno. Njezina boja mora biti jednaka kad se promatra pod ELA, neovisno o njezinoj stvarnoj boji. Na **slici 5** vidi se značajnija razlika u kompresiji kod letećeg objekta, njegove sjene i padobrana, što ukazuje na to da su ti elementi vjerojatno naknadno dodani. Grad ispod je neka vrsta teksture i, iako izgleda drugačije, ujednačeno je pa se može zaključiti da tu vjerojatno nema nekih izmjena osim na području sjene jer tamo dolazi do drugačijeg obojenja.

Slika 4: Modificirana slika

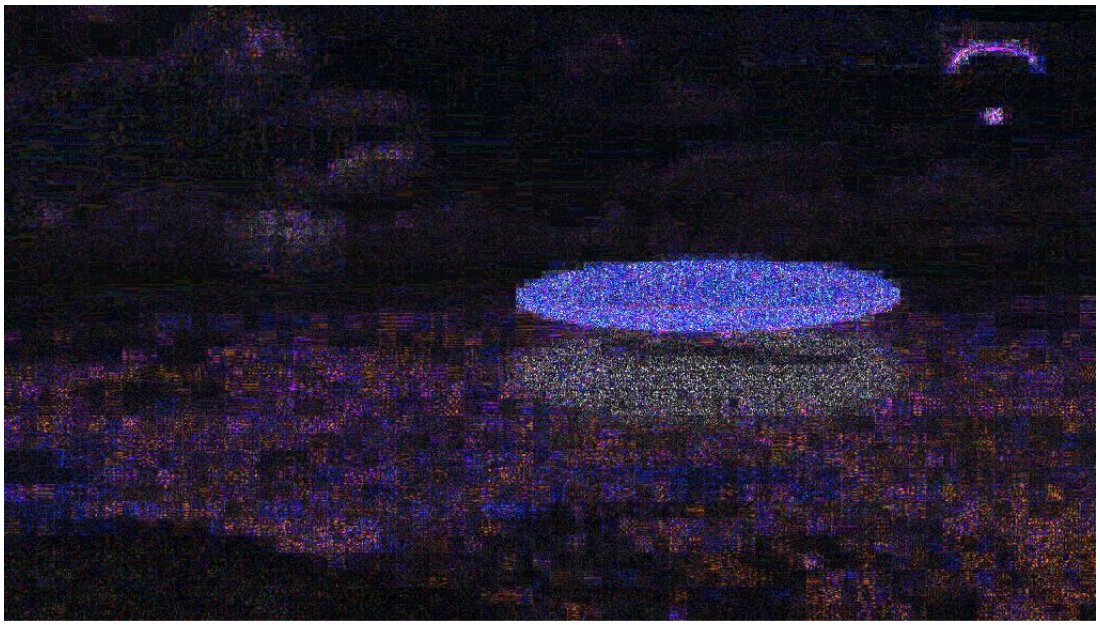

Slika 5: Error level analysis nad slikom

3.4 Analiza šuma

Šum je dio signala koji nije koristan. Jaki šumovi se na slici vide kao neka neobična tekstura ili općenito izobličenje, ali većinu šumova zapravo ne vidimo. Analiza šuma (engl. *noise analysis*) koristi filter koji izvlači isključivo šum sa slike. [3] Ako se na nekom području javlja neobično jak šum, to ukazuje na manipulaciju na tom dijelu. Metoda radi bolje što je slika kvalitetnija jer nekvalitetna slika će sama o sebi imati puno šuma pa će biti manja razlika između područja s više i manje šuma. Primjerice, na **slici 7** vidi se jak šum u području letećeg objekta i sjene ispod njega te kod padobrana, što daje neku dozu sigurnosti da su ta dva objekta umetnuta.

Slika 6: Modificirana slika

Slika 7: Analiza šuma nad slikom

3.5 Analiza glavnih komponenti

Analiza glavnih komponenti (engl. *Principal component analysis,* skraćeno PCA) općenito se koristi u obradi signala, pa se može koristiti i u obradi slika. [8] To je tehnika koja smanjuje dimenzionalnost podataka i tako ih pojednostavljuje. PCA je zapravo nenadzirano učenje – pronalaze se sličnosti među podatcima bez ikakvog znanja o njima. Pri analizi slike pikseli se klasificiraju tom metodom da bi se mogli

grupiralti u komponente. Prva se komponenta bira na način da se minimizira ukupna udaljenost između podataka. Sve daljnje komponente biraju se na isti način uz dodatni kriterij da budu neovisne o svim prethodnim komponentama, odnosno da korelacija među svim komponenatama bude jednaka nuli. Dakle, nakon analize, komponente postaju međusobno nezavisne i to je ono što olakšava daljnje traženje manipulacija nad njima. U alatima koji omogućuju PCA korisnik sam bira redni broj komponente koju želi izdvojiti i taj broj odlučuje o tome hoće li PCA dati konkluzivne rezultate ili ne. [5]

Slika 9: Izmijenjena slika

Slika naoko nema nikakvih izmjena, ali služi kao dobar primjer da se pokaže kako izbor komponente koju koristimo za PCA utječe na to hoćemo li dobiti konkluzivne rezultate. **Slika 10** prikazuje analizu samo nad prvom komponentom koja ne detektira ništa, dok **slika 11** prikazuje analizu nad drugom komponentom i tamo se uočava izmjena pri sredini slike. Autor slike navodi da je na tom mjestu uklonio muhu koja je proletjela ispred kamere.

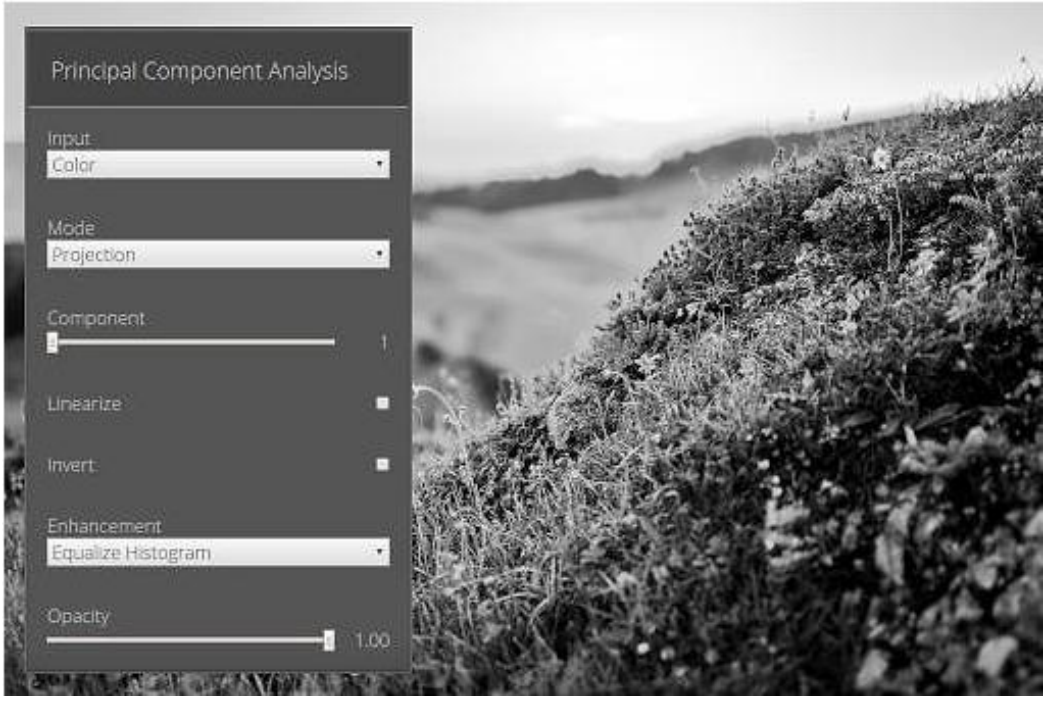

Slika 10: PCA koristeći prvu komponentu

Slika 11: PCA koristeći drugu komponentu

3.6 Analiza JPEG tablica

JPEG slike koriste kompresiju s gubitkom, što znači da mogu značajno smanjiti veličinu neke slike. [7] Budući da kompresija ima gubitak, ireverzibilna je. Također,

kompresija uzrokuje nastanak BAG (engl. *block artificial grid*) koji se javlja na rubovima piksela. Pri nepromijenjenoj slici, BAG-ovi nalaze se samo na rubovima blokova. Ako je slika mijenjana, znači da je barem još jednom spremljena, a svako spremanje u JPEG formatu radi kompresiju. Osim što će se smanjiti kvaliteta slike, moguće je da se BAG nađe negdje u sredini bloka i tako se može detektirati modifikacija.

Kompresija ima šest koraka, ali korak koji je važan za ovu analizu je **kvantizacija**. U tom se koraku decimalni brojevi dobiveni u prethodnim koracima kvantiziraju u cijele. Time se određuje koliko će biti jaka kompresija na tom dijelu slike. Ne mora svaki dio slike biti u jednakoj mjeri komprimiran. Primjerice, ako slika prikazuje veliko područje približno iste boje, kompresija može će jača nego na području s više detalja. Podatci o tome koliko je točno informacije izgubljeno u kompresiji pohranjene su u **kvantizacijskoj tablici**. Uobičajene kvantizacijske tablice imat će šarolike vrijednosti, dok će photoshopirane i AI generirane slike imati pretežno male vrijednosti u kvantizacijskoj tablici. Također, neki alati već sami znaju označiti koja tablica je standardna, a koja pripada nekom photoshop alatu. Primjeri su pokazani u **slikama 12 i 13.**

Standard JPEG Table Quality=75

Table 0 (8 bit)

8	6	6	7	6	5	8	7
7	7	9	9	8	10	12	20
13	12	11	11	12	25	18	19
15	20	29	26	31	30	29	26
28	28	32	36	46	39	32	34
44	35	28	28	40	55	41	44

Slika 12: Standardna JPEG kvantizacijska tablica

photoshop 100

Table 0 (8 bit)

1	1	1	1	1	1	1	1
1	1	1	1	1	1	1	1
1	1	1	1	1	1	1	1
1	1	1	1	1	1	1	1
1	1	1	1	1	1	1	1
1	1	1	2	2	2	2	2
2	2	2	2	2	2	3	3

Slika 13: JPEG kvantizacijska tablica photoshopirane fotografije

3.7 Analiza gradijenta osvjetljenja (engl. *Luminence gradient)*

Slika se pri analizi često pretvara u binarni format. [2] Dakle, piksel koji je “upaljen” se označava s 1, a “ugašen” s 0. Budući da su slike analogne, potrebno je naći prag koji određuje je li piksel upaljen ili ugašen. Prag se u rasponu [0, 1], pri čemu granične vrijednosti nemaju smisla jer bi onda cijela slika vraćala istu vrijednost. Taj prag zove se **razina osvjetljenja** (engl. *luminence level*). Idealna vrijednost ovisi o samoj slici, ali je dobro krenuti od 0.5 i isprobavati dalje.

Očekivano je da će slika imati jednoliku svjetlost ako je napravljena s jednom kamerom. Teško je definirati što znači jednolika svjetlost pa se koristi **gradijent slike**. On se definira kao usmjerena promjena razine osvjetljenja na slici. Očekivano, gradijent bi trebao biti podjednak u područjima koja su blizu jer su ta područja jednako udaljena od kamere i približno jednakog osvjetljenja jer su a sličnoj poziciji. Naravno, izuzetak je ako je jedan od objekata u sjeni. Dakle, ako se javi značajna razlika u tom gradijentu na mjestu gdje to kontekstualno nema smisla, to ukazuje na sumnju da je taj objekt umetnut. Umetnut objekt je sigurno sniman drugom kamerom u drugo vrijeme pri drugačijem svjetlu i teško je pogoditi da osvjetljene bude jednako kao na slici u koju se objekt umeće pa ova metoda može dati dobre rezultate.

Na **slikama 14 i 15** vidi se neobično jak gradijent kod umetnutog letećeg objekta i padobrana.

Slika 14: Izmijenjena slika

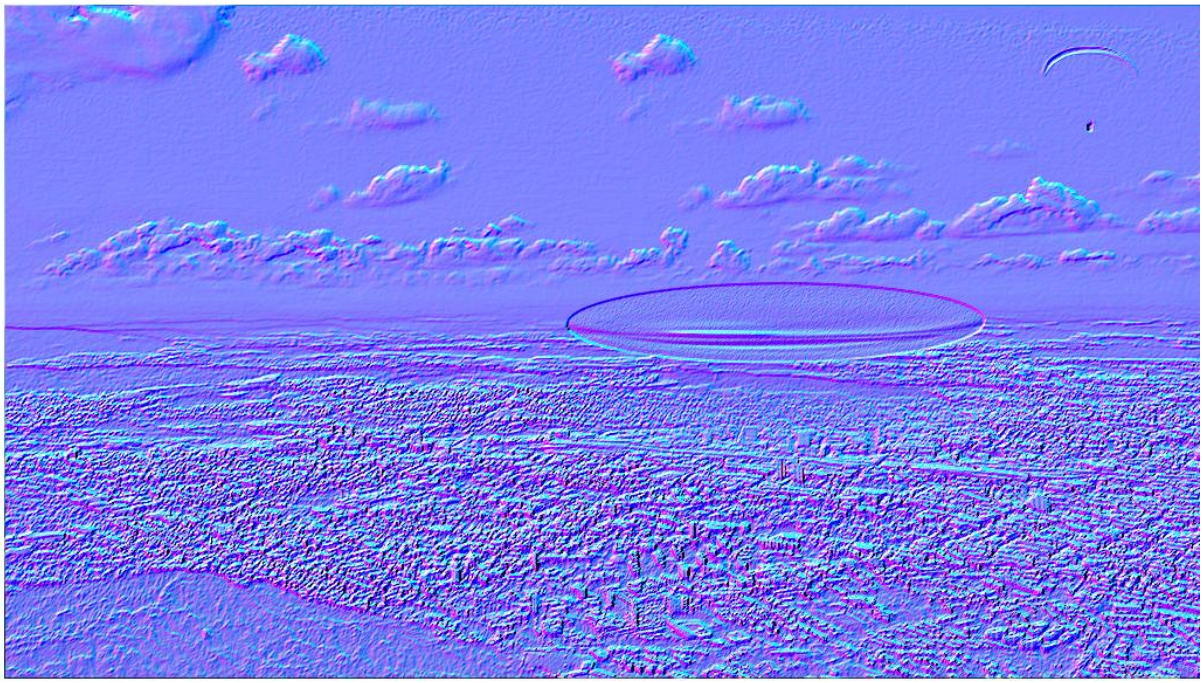

Slika 15: Luminence gradient nad slikom

4. Sažetak

Ovaj seminarski rad daje kratak pregled metoda forenzičke analize koje utvrđuju je li neka slika mijenjana i, ako je, točno na koji način i na kojem mjestu. Većina rada posvećena je detekciji umetnutih i uklonjenih objekata. Objašnjeni su principi nekih kompliciranijih metoda poput korištenja algoritama za detekciju rubova objekata, korištenje HSV prikaza slike i podjela slika na blokove ili ključne točke. Za neke metode za koje postoje komercijalni alati uz objašnjene demonstrirano je i kako metoda radi. Demonstrirane metode su jednostavna *copy-clone* detekcija, *Error level analysis*, analiza glavnih komponenti, analiza šuma, analiza JPEG tablica i analiza gradijenta osvjetljenja.

5. Zaključak

Važno je napomenuti da svaka od ovih metoda samo ukazuje na izmjenu slike i da niti jedna sama za sebe ne može pouzdano reći je li slika mijenjana ili ne. Jedino kad je to moguće je ako je izmjena vrlo očita, a u toj situaciji najčešće nije ni potreban alat. Međutim, rezultati provođenja ovih metoda u kombinaciji s drugim dokazima mogu doći do konkluzivnih rezultata. Zato se forenzičke metode često koriste kao dopuna policijskom istraživanju.

6. Literatura

[1] K. H. Hingrajiya and R. K. Sheth, “Comparative Study of Digital Image Forgery Detection Techniques,” in 2021 International Conference on Advance Computing and Innovative Technologies in Engineering (ICACITE), Mar. 2021, pp. 83–86. doi: 10.1109/ICACITE51222.2021.9404748.

[2] S. Murali, B. S. Anami, and G. B. Chittapur, “Detection of Copy-Create Image Forgery Using Luminance Level Techniques,” in 2011 Third National Conference on Computer Vision, Pattern Recognition, Image Processing and Graphics, Dec. 2011, pp. 215–218. doi: 10.1109/NCVPRIPG.2011.53.

[3] P. Pale, J. Petrović, L. Vlatković, M. Dragošević , „Metode otkrivanja izmjena u digitalnim fotografijama“, predavanja iz predmeta Forenzika digitalnih sadržaja, 2024.

[4] “FotoForensics.” Accessed: Apr. 14, 2025. [Online]. Available: https://fotoforensics.com/tutorial-ela.php

[5] “Principal Component Analysis for Photo Forensics,” 29a.ch by Jonas Wagner. Accessed: Apr. 14, 2025. [Online]. Available: https://29a.ch/2016/08/11/principal-component-analysis-for-photo-forensics

[6] R. Idlbek, M. Pešić, and K. Šolić, “Enhancing Digital Image Forensics with Error Level Analysis (ELA),” in 2024 47th MIPRO ICT and Electronics Convention (MIPRO), Opatija, Croatia: IEEE, May 2024, pp. 1555–1560. doi: 10.1109/MIPRO60963.2024.10569232.

[7] J. D. Kornblum, “Using JPEG quantization tables to identify imagery processed by software,” Digital Investigation, vol. 5, pp. S21–S25, Sep. 2008, doi: 10.1016/j.diin.2008.05.004.

[8] J. Lever, M. Krzywinski, and N. Altman, “Principal component analysis,” Nature Methods, vol. 14, no. 7, pp. 641–642, Jul. 2017, doi: 10.1038/nmeth.4346.

[9] S. Patil, P. Padiya and S. Chaudhari, "A Detailed Analysis of Image Forgery Detection Techniques and Tools," 2023 World Conference on Communication & Computing (WCONF), RAIPUR, India, 2023, pp. 1-6, doi: 10.1109/WCONF58270.2023.10235124.