Sveučilište u Zagrebu
Fakultet elektrotehnike i računarstva
Zavod za elektroničke sustave i obradbu signala
Laboratorij za sustave i signale

Forenzika digitalnih sadržaja
Seminarski rad

Rekonstrukcija digitalnih fotografija

Zrinka Cvitanović

18.6.2025.

Ovaj studentski seminarski rad izrađen je u okviru predmeta

Forenzika digitalnih sadržaja

Autor/student odgovara za sadržaj

uključujući korištenje tuđeg intelektualnog vlasništva

Mentori:

Izv. prof. dr. sc. Predrag Pale

Doc. dr. sc. Juraj Petrović

Sadržaj

Problem/zadatak 3

Temeljni pojmovi 3

Gradijent slike 3

Fourierova transformacija 3

TV operator 4

Benfordov zakon 4

Detekcija i rekonstrukcija copy-clone izmjene 5

1. Metoda zasnovana na Benfordovu zakonu 8

2. GradientOMP algoritam 10

Zaključak 13

Odgovori na pitanja 13

Literatura i reference 14

Problem/zadatak

Kao što se fizička slika može oštetiti, isto tako se može oštetiti i digitalna slika. Često je u pitanju oštećenje medija za pohranu. Rekonstrukcija se ne mora uvijek odnositi na sliku koja je nekoć bila dobre kvalitete pa se oštetila, već se odnosi i na slike koje su u svom izvornom obliku loše čitljive za ljudsko oko. Trenutačno se metode rekonstrukcije najčešće koriste u medicinskim nalazima jer su oni puni šuma. Metode opisane u ovom seminaru neće se baviti rekonstrukcijom bitova nekog oštećenog fizičkog diska, već rekonstrukcije slike u svrhu poboljšanja čitljivosti. Za takvu rekonstrukciju nije potrebno poznavanje medija na kojem je slika bila pohranjena, već se sve potrebne informacije mogu izvući iz slike.

Savršena rekonstrukcija slike je, barem zasad, nemoguća. No, postoje mnoge primjene gdje je i to što se dobije dovoljno dobro. Forenzičari već dugo pokušavaju naći načine kako rekonstruirati što senzor zapravo „vidi“ iz onoga što se vidi na slici. Te su metode bazirane na složenoj matematici tako da ovaj rad neće ulaziti u detalje svake od njih. Ideja je pokazati u kojem smjeru znanstvenici razmišljaju i potencijalno dati inspiraciju za neku novu ideju. Također, pokazat će se metoda koja rekonstruira jednostavnu manipulaciju slike, tzv. copy-move izmjenu.

Temeljni pojmovi

Prije objašnjavanja metoda rekonstrukcije potrebno je objasniti neke pojmove vezane uz analizu slike.

Gradijent slike

Gradijent slike definira se kao usmjerena promjena slike. [3] Gradijent se koristi za mnoge metode obrade slike, primjerice detekciju rubova, jer su pikseli s visokim gradijentom najčešće rubovi objekata. Koristi se i za usporedbu slika koje imaju različito osvjetljenje jer je računanje gradijenta manje osjetljivo na promjenu osvjetljenja u odnosu na neke druge metode.

Budući da je gradijent vektor, on ima orijentaciju i iznos. **Orijentacija** gradijenta definira se kao smjer najveće promjene intenziteta na slici, a **iznos** gradijenta kao snaga promjene intenziteta na slici.

Fourierova transformacija

Fourierova transformacija često se koristi u obradi signala jer je računalno učinkovita i ima inverznu operaciju. [2] Dakle, ako za neki signal ima *d* komponenti i poznajemo svih *d* koeficijenata Fourierove transformacije, izvođenjem inverzne Fourierove transformacije možemo dobiti izvorni signal. Naravno, slike su složeni signali i nemoguće je imati svih *d* koeficijenata, odnosno, da ih imamo, problem bi bio trivijalan. Razlog zašto tih koeficijenata ima puno je zbog složenosti signala, ali i zbog

mnogo šuma koji se stvara, posebice kod medicinskih nalaza. Istraživanja su pokazala da se za signale koji su „rijetkog gradijenta“ (engl. *sparse gradient,* gradijent je većinom 0 uz povremene iznimke) u nekim bazama, može se postići rekonstrukcija čak i uz poznavanje *n << d* koeficijenata Fourierove transformacije. Želja je da se smanji broj potrebnih parametara koje treba poznavati da bi se slika rekonstruirala, što znači da i instrumenti mogu biti jednostavniji i da se može obrađivati manje podataka. Zato se takve paradigme rekonstrukcija slika obično nazivaju „kompresijskima“.

TV operator

Operator totalne varijacije (engl. *Total-variant operator,* TV) je najveća razlika funkcijske vrijednosti dviju susjednih točaka definirana na ovaj način:

$$V_a^b\left(f\right) = sup \sum_{i=0}^{n_p-1} \left| f\left(x_{i+1} - f\left(x_i\right)\right) \right|$$

U praksi se koristi za izdvajanje stvarnog signala od šuma [7]. Izdvajanje je moguće i metodom najmanjih kvadrata, tzv. L2 metodom, no s vremenom je ustanovljeno da su rezultati bolji ako se nastoji minimizirati TV operator. Postoji više metoda koje se bave minimizacijom vrijednosti totalne varijacije slike, međutim njihov glavni nedostatak je da operator TV nije invertibilan [2]. To znači da ne možemo direktno dobiti koeficijente Fourierove transformacije slike TV(X) koristeći koeficijente Fourierove transformacije slike X. Iz tog razloga ta metoda nije uvijek učinkovita.

Benfordov zakon

Metode za rekonstrukciju slika zasnovane na Bayesu temelje se na minimizaciji energijske funkcije[1]:

$$E(Y,X) =- \ logp(X) - log(p(X))$$

pri čemu je X slika koju želimo rekonstruirati, a Y slika koju vidimo. Problem je što rezultati ovog postupka jako ovise o inicijalnom izboru hiperparametara koji se teško procijene.

1881. primijećena je pravilnost u slikama koja je danas poznata kao **First digit law.** Prvi ju je zapravo zamijetio Simon Newcomb, ali je fizičar Benford potvrdio eksperimentalnim testovima da ona zaista postoji. Zato se zakon često naziva i **Benford-Newcombov zakon**. Naime, ako se uzme skup realnih signala, statistička distribucija prve značajne znamenke nije uniformna kako bi se očekivalo, već prati logaritamsku distribuciju:

$$\mathrm{p}(n) = k * log(1 + n - 1)$$

gdje je k normalizacijska konstanta, a n očekivana najznačajnija znamenka. Dakle, p(n) poprima vrijednosti

$$\mathrm{p}(n) = \{0.301, 0.176, 0.125, 0.097, 0.079, 0.067, 0.058, 0.051, 0.046\}$$

Laički rečeno, u stvarnim numeričkim podatcima (koji se mogu reprezentirati kao signali), najznačajnija će znamenka većinom biti malena. Što je znamenka veća, njezina je vjerojatnost pojavljivanja manja. Vidi se da je otprilike u 30% slučajeva vodeća znamenka 1, a u manje od 5% je 9. Kad bi vrijedila uniformna distribucija, za svaku znamenku bila bi jednaka vjerojatnost od otprilike 11,11%.

Osim za rekonstrukciju slika koristi se i za detekciju izmjene slike jer, ako vrijednosti ne prate ovu krivulju, obično je u pitanju neka vrsta lažiranja slike. Zakon se ne odnosi samo na piksele u slikama, već i na ostale numeričke podatke. Problem je što zakon nije primjenjiv na malim skupovima podataka. Također, kad su podatci korelirani, može doći do odstupanja.
Kasnije je primijećeno da se ova pravilnost može generalizirati na ostale znamenke osim prve. No, ono što je relevantno za slike je da gradijent na prirodnim slikama također prati taj zakon. Također, ako se pretpostavi da vrijedi Benfordov zakon, tada se uklanja problem traženja inicijalne distribucije. Distribucija gradijenta može se opisati jednadžbom:

$$\mathrm{p(gi)} = \mathrm{k} \,/\, \mathrm{gi}$$

pri čemu je k normalizacijska konstanta, a g_i gradijent na i-tom pikselu. Pokazano je da ta pretpostavka vrijedi za MRI, CT i ultrazvučne slike.

Pitanja

1. Zašto je korisno uspoređivati dvije slike prema gradijentu?
2. Zašto su slike “rijetkog gradijenta” spretne za obradu Fourierovom transformacijom?
3. Što govori Benfordov zakon o vjerojatnostima za vrijednost prve značajne znamenke?

Detekcija i rekonstrukcija copy-clone izmjene

Copy-clone izmjena najjednostavnija je izmjena za otkriti i rekonstruirati na slici. Ona se provodi tako da se jedan dio slike kopira i zalijepi negdje na *istoj* slici. Neke metode mogu samo detektirati izmjene i locirati ih, a metoda opisana i nastavku uključuje detekciju izmjene i rekonstruiranje originalne slike. [6] Ova metoda ima 4 koraka:

1. identificiranje modifikacije
2. pretpostavka transformacije (koja je i kolika)
3. identifikacija točnih regija koje su duplicirane
4. rekonstrukcija originalne slike

Prvi korak izvlači značajke slike koristeći SIFT (engl. *Scale Invariant Feature Transform*) metodu. Na svakoj slici postoje **ključne točke**. To su točke na slici koje nose informaciju važnu za značenje slike. Metoda prvo nalazi SIFT ključne točke slike i njihove opisne značajke (pozicija, veličina, orijentacija i sl.). Naziv metode kaže da je neosjetljiva na skaliranje, što je vrlo važno svojstvo jer se zalijepljeni objekt često skalira da bi bolje pristajao području gdje je umetnut. Neosjetljivost na skaliranje osigurava se normalizacijom histograma slike. Nakon što su se točke pronašle, traže se podudarne ključne točke korištenjem metode 2-NN najbližeg susjeda (engl. *matching*). 2-NN znači da se svakoj točki uzimaju 2 najbliža susjeda i na temelju njih se određuje kojoj „klasi“ se točka pridružuje. Mjerenje je ponderirano, dakle bliži susjed ima prednost ako susjedi pripadaju različitim klasama. Ovom metodom se ključne točke grupiraju u klastere.

U **drugom** koraku se uzima u obzir da dupliciranо područje može biti izmijenjeno – rotirano, skalirano, odrezano i slično. Nad klasterima identificiranima u prvom koraku se rade usporedbe jer se često u istom klasteru nađu točke koje zapravo nisu toliko slične. Na temelju popravljenih klastera na kraju koraka pretpostavi se funkcija koja opisuje transformaciju kloniranog objekta.

Treći korak gleda korelaciju među regijama. Korelacija radi samo nad precizno kloniranim regijama, dakle bez izmjena. Osnovna je ideja usporediti svaki piksel slike s njezinim potencijalnim duplikatom (engl. *counterpart*). Potencijalni duplikat pronalazi se preko pretpostavljene afine transformacije iz drugog koraka. Ne možemo razlikovati original od kopije, stoga se nad oba piksela treba uzeti i i inverz transformacije. Rezultati ovog koraka su korelacijske mape *cfx* transformacije i mape *cbx* koja se dobije provođenjem inverza transformacije.

U **zadnjem** koraku koristimo korelacijske mape *cfx* i *cbx*. To su u suštini binarne slike iz kojih se mogu otkriti važne značajke koje se koriste u koraku rekonstrukcije. Na područje koje se smatra kloniranim dodaje se pravokutnik (engl. *bounding rectangle*). Zatim se gleda intenzitet svakog ugla tog pravokutnika na sivoj skali. Ako su svi intenziteti različiti, rekonstrukcija je nemoguća jer to znači da pozadina nije uniformna. Nužan je uvjet da su barem dva jednaka i u tom se slučaju cijeli područje pravokutnika ispuni bojom intenziteta gornjeg lijevog kuta. Slika prikazuje primjer originalne, modificirane i rekonstruirane slike.

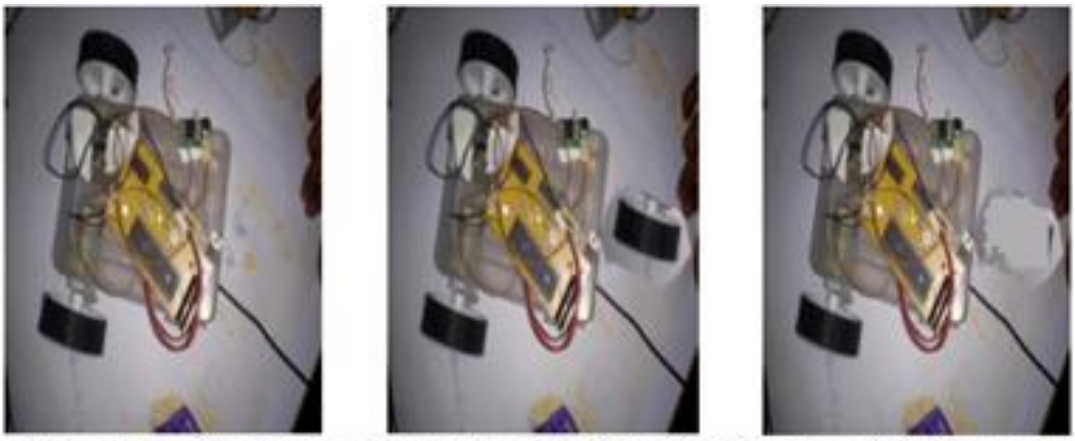

Fig.3 Verification of result: (a) Original image (b) forged input image (c) reconstructed image

Slika 1

Slika 2 prikazuje cijeli proces:

a. modificirana slika
b. pretprocesirana slika (prebaci se u sivu skalu)
c. traženje SIFT točaka (označeno svijetloplavo)
d. rezultati traženja podudarnih ključnih točaka (crvene linije)
e. rezultat razvrstavanja u klastere – jedan je tamnoplav, drugi žut
f. korelacijska mapa
g. dodavanje *bounding rectangle* na duplicirano područje
h. rekonstruirana slika – vidi se da se koristio intenzitet na dva desna kuta pravokutnika

Koraci a – d pripadaju prvom koraku, e drugom, f trećem te g i h četvrtom.

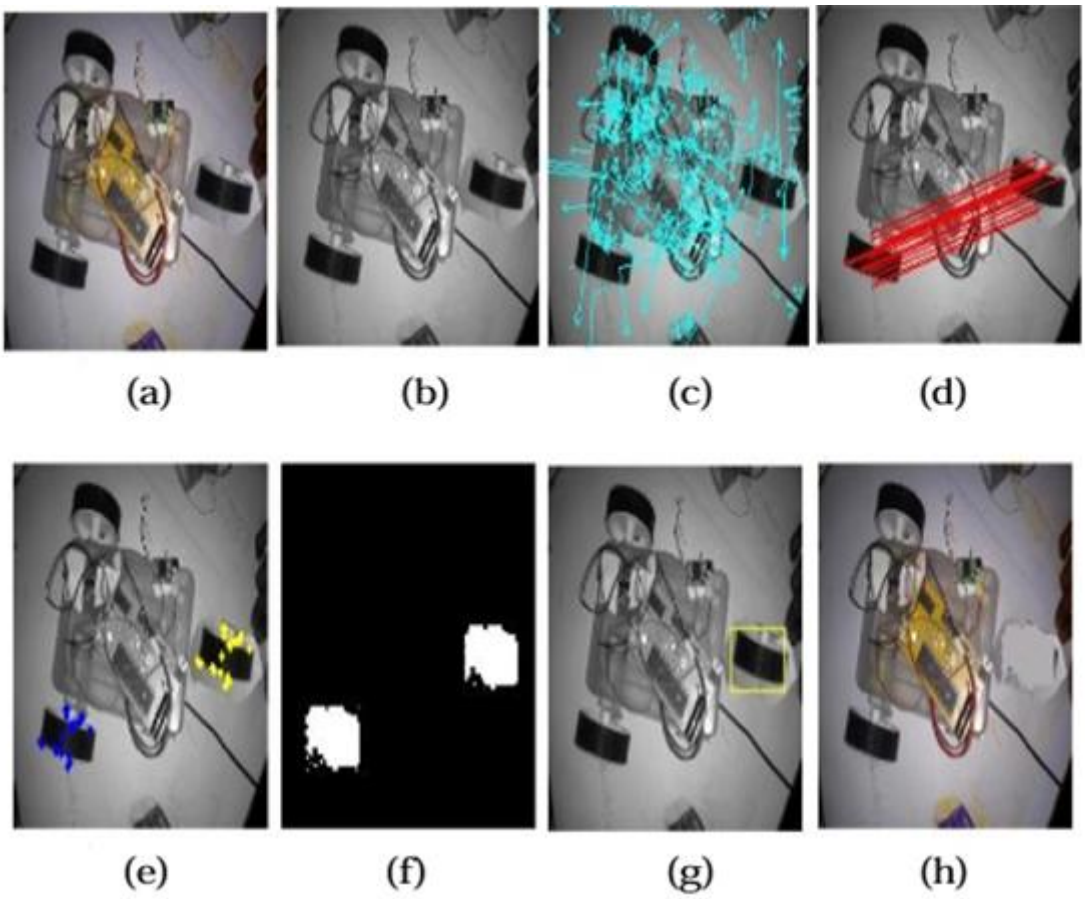

Slika 2

Da bi se još sa sigurnošću utvrdilo koji je dio slike klon, a koji original, dodaje se zadnji korak a to je detekcija *splicinga* na slici. *Splicing* znači izrezivanje jednog dijela slike i lijepljenje na istu ili drugu sliku. Dio slike koji je nalijepljen karakteriziran je neprirodno velikim šumom jer zaista ni ne pripada toj slici. Da bi se odredila vrijednost šuma originalne slike može se iskoristiti je Laplaceov operator. Njegova je prednost što je gotovo neosjetljiv na strukturu slike, odnosno osjetljiv je samo na šum i nema drugih parametara slike o kojima je ovisan. Ako je šum u intervalu [0.6, 1.4] na nekom dijelu slike, on se smatra nadodanim.

1. Metoda zasnovana na Benfordovu zakonu

Svi rekonstrukcijski algoritmi bave se minimizacijom funkcije E(X,Y) po X[1]:

$$E(Y,X) = -logp(X) - logp(X)$$

Dakle, formuliran problem izgleda ovako:

$$X = argmin \;\; E(Y,X)$$

Ova metoda pretpostavlja da je X Markovljevo nasumično polje (MRF), pa se pretpostavlja da je inicijalne distribucija podataka Gibbsova:

$$p(X) = Z^{-1} - e^{-\alpha U(x)}$$

$$U(X) = \sum v(\delta_{iv}, \delta_{ih})$$

Pri čemu je značenje pojedinih konstanti prikazano u **tablici 1.**

Tablica 1: Značenje pojedinih konstanti u Gibbsovoj distribuciji

α	unaprijed određen parametar Gibbsove distribucije
Z	normalizacijska konstanta
v()	potencijalna funkcija
δ_{iv}	razlika gradijenta susjednih **vertikalnih** piksela
δ_{ih}	razlika gradijenta susjednih **horizontalnih** piksela

Ako se pretpostavi Benfordov zakon i neovisnost gradijenata, vrijedi

$$p(G) = W^{-1} e^{-\sum i log(gi)}$$

Pri čemu je W normalizacijska konstanta. Iznos gradijenta gi u i-toj točki može se pretpostaviti koristeći izraz

$$g_i = \sqrt{{\delta_{iv}}^2 + {\delta_{ih}}^2}$$

Kao primjer je odabrana funkcija $v(\delta_{iv}, \delta_{ih}) = \log(gi)$

Nakon toga radi se iterativna minimizacija funkcije E(X, Y) i tako se dobije funkcijska ovisnost X i Y. Metoda se koristi većinom za uklanjanje šuma iz medicinskih slika i pokazala se uspješnom i za slike koje prirodno sadrže šum i za slike kojima se dodaje aditivni Gaussov šum. Primjeri kako metoda radi na CT -u (prvi red), MRI (drugi red) i neke sintetičke slike (treći red) prikazani su na slici 3. U prvom stupcu nalaze se originalne slike, u drugom slike s Gaussovim aditivnim šumom (σ=20) .

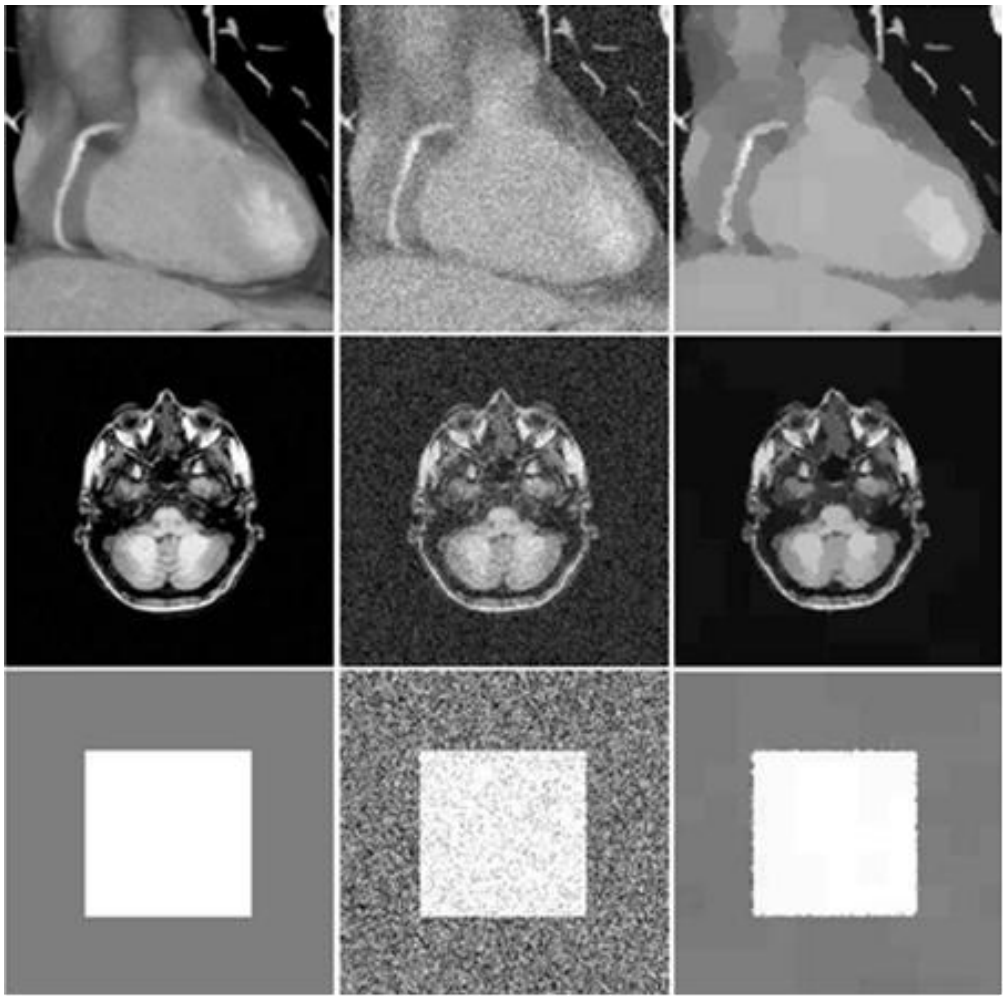

Slika 3: Primjer rada metode

2. GradientOMP algoritam

Već od prije postoji algoritam **OMP** (*Orthogonal matching pursuit*) koji je učinkovit za slike koje su „rijetke“ po Euklidovoj bazi, međutim takve su slike vrlo rijetke. Češće su slike rijetkog gradijenta zato što imaju puno područja konstantne vrijednosti koja su odvojena nekim rubom. Ovaj predložen algoritam uzima neka svojstva algoritma OMP, ali ih čini prikladnijima za uobičajene slike. [2]

Metoda je predložena u znanstvenom radu 2007. Koristi deriviranje jer je ono inverzan operator. Intuitivno je to svojstvo važno jer je rekonstrukcija slike zapravo postupak unatrag – od oštećene slike želimo se vratiti u vrijeme kad je ona bila kvalitetna. Slike koje su po prirodi nastanka loše mogu se tretirati kao da su nekoć bile jasne i čitljive pa je nad njima naknadno nastalo oštećenje. Metoda pretpostavlja sliku rijetkog gradijenta, misleći se na onu čiji je gradijent rijedak kad se nad njom provede TV operator. To ne znači nužno da je originalna slika isto takva. **Slika 4** pokazuje takav primjer.

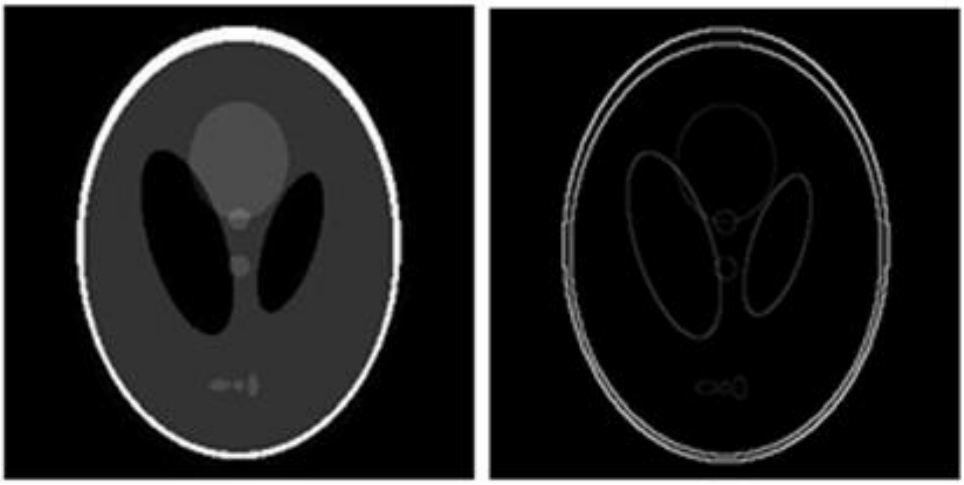

Slika 4: Lijeva slika (original) nije rijetkog gradijenta, dok slika pod TV operatorom (desno) jest*Ideja*

Algoritam se većinom oslanja na znanju o gradijentu slike pa su ga autori rada nazvali **GradientOMP.** Ideja je sljedeća:

1. Uzme se vertikalna derivaciju D_v i horizontalna D_h. Definiraju se na ovaj način:

$$(D_v X)_{i,j} = X_{i,j} - X_{i-1,j} \; (D_h X)_{i,j} = X_{i,j} - X_{i,,-1j}$$

Derivacije su inverzne, dakle vrijedi:

$$\left(D_v^{-1} X\right)_{i,j} = \sum_{k=1}^{i} X_{k,j}$$

2. Integrira se horizontalno i vertikalno. Primjerice, za vertikalno vrijedi:

$$\left(D_v^{-1} D_v X\right)_{i,j} = X_{i,j} + H_{i,j}$$

Pri čemu je H slika koje je konstantna u vertikalnom smjeru. Sad se radi integracija u horizontalnom smjeru:

$$(D_h H)_{i,j} = (D_h^{-1} D_v X)_{i,j} - (D_h) X_{i,j}$$

3. Iz sustava jednadžbi dobije se H, oduzme ga od $(D^{-1} D_v X)$ i na temelju toga radi procjena X.

4. Ukratko, algoritam želi dobiti $D_v X$ I $D_h X$ neovisno koristeći OMP, a zatim procijeniti X metodom koja je računalno učinkovitija.

Zanimljivo je da ovaj algoritam može izazvati neke očite greške (primjerice, pojavit će se vertikalne linije na slici koje nisu prije postojale), ali uvijek zadržava sva važna svojstva slike. S druge strane,

običan OMP ne izaziva nikakve očite greške, ali može zamutiti neke detalje što u medicinskim nalazima predstavlja problem. **Slike 5 i 6** pokazuju usporedbu GradientOMP metode i klasične minimizacije TV operatora

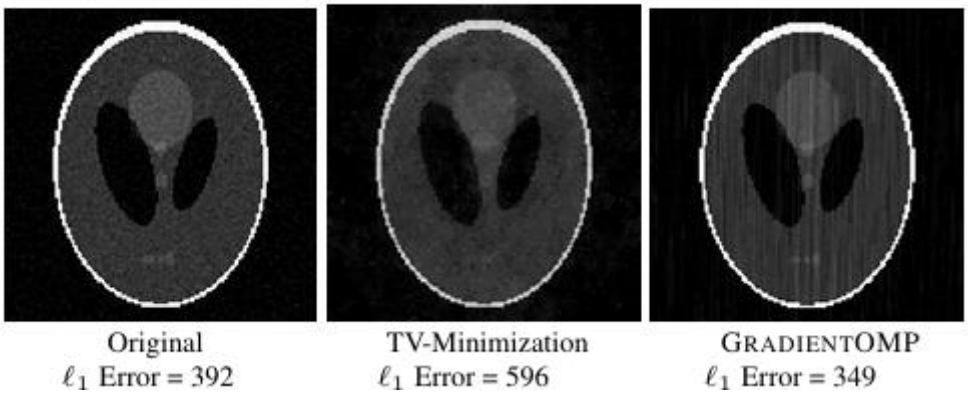

Slika 5

Slika 6

Vidi se da je srednja slika uvijek zamućena, a na desnoj se nalaze vertikalne linije.

Pitanja

4. Što je nedostatak običnih blokovskih metoda pri detekciji copy-clone izmjene?

5. Koju vrijednost na slici metoda rekonstrukcije bazirana na Benfordovu zakonu pokušava procijeniti?

6. Koji je nedostatak GradientOMP metode?

7. Zašto se metoda svejedno koristi?

Zaključak

Iako su znanstvenici vrlo kreativni, činjenica je da i dalje ne postoji metoda koja bi bila računalno učinkovita, a istovremeno dovoljno dobro rekonstruirala sliku da ju čovjek bez problema može interpretirati. Optimistično je znati da je ova tema zanimljiva znanstvenoj zajednici i da se na njoj radi jer postoji mnogo radova na ovu temu. Većina suvremenih radova predlaže metode zasnovane na dubokom učenju, međutim još ne postoje (ili nisu javno dostupne) metode s konkretnim rezultatima.

Odgovori na pitanja

1. Zato što je gradijent manje osjetljiv na osvjetljenje, a različite slike istog objekta će gotovo uvijek imati različito osvjetljenje
2. Zato što je potrebno znati mnogo manje od *n* koeficijenata F.T. nego što je dimenzija signala
3. Raspodjela nije uniformna, već je veća vjerojatnost da je znamenka manja (veće znamenke se rjeđe pojavljuju)
4. Blokovska metoda gleda jesu li blokovi *potpuno* isti, a to je vrlo rijetko slučaj. Često se kopirani isječak rotira i/ili skalira, a blokovski algoritimi su osjetljivi na takve promjene
5. Gradijent slike u određenoj slici.
6. Javljaju se vrlo očite greške (primjerice vertikalne linije)
7. Zato što ne zamućuje sliku, za razliku od nekih prijašnjih metoda

Literatura i reference

[1] J. Sanches and J. S. Marques, “Image Reconstruction using the Benford Law,” in 2006 International Conference on Image Processing, Oct. 2006, pp. 2029–2032. doi: 10.1109/ICIP.2006.312845.

[2] R. Maleh, A. C. Gilbert, and M. J. Strauss, “Sparse Gradient Image Reconstruction Done Faster,” in 2007 IEEE International Conference on Image Processing, Sep. 2007, p. II-77-II–80. doi: 10.1109/ICIP.2007.4379096.

[3] “What Is Gradient Orientation and Gradient Magnitude? | Baeldung on Computer Science.” Accessed: Apr. 17, 2025. [Online]. Available: https://www.baeldung.com/cs/gradient-orientation-magnitude

[4] A. Chambolle, V. Caselles, M. Novaga, D. Cremers, and T. Pock, “An introduction to Total Variation for Image Analysis,” Nov. 2009. Accessed: Apr. 17, 2025. [Online]. Available: https://hal.science/hal-00437581

[5] “TVHandbook6.dvi.” Accessed: Apr. 17, 2025. [Online]. Available: https://people.dm.unipi.it/novaga/papers/chambolle/TVHandbook/TVHandbook6.pdf

[6] “(PDF) Image Reconstruction in Digital Forensics.” Accessed: Apr. 17, 2025. [Online]. Available: https://www.researchgate.net/publication/356344190_Image_Reconstruction_in_Digital_Forensics

[7] “(PDF) Nonlinear total variation based noise removal algorithms.” Accessed: Apr. 17, 2025. [Online]. Available: https://www.researchgate.net/publication/222469583_Nonlinear_total_variation_based_noise_removal_algorithms